Centro Universitário de Excelência
Sistemas de Informação

MecâniQA Salvador
Baseline e Métricas de Avaliação

Autores: Albert Santos Soares
Juan Pablo Barros Carvalho
Matheus Espírito Santo dos Santos
Rafael Pires Araujo
William Bichara

Vitória da Conquista – BA, 2026

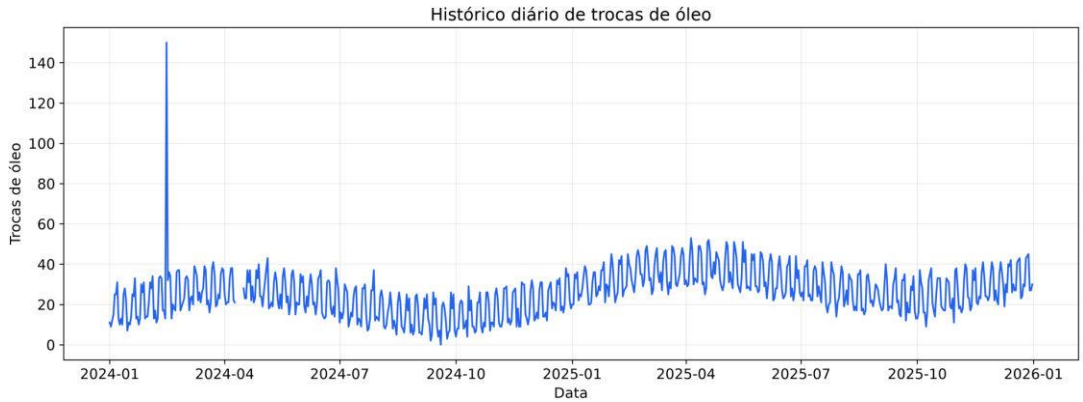
Agenda

1. **Baselines:**
   Naive e Média Móvel
2. **Boas práticas: shift(1) e Data Leakage**
3. **Validação: TimeSeriesSplit e métricas**
4. **Feature Engineering: Lags 1, 7 e 30 + Rolling Window**
5. **Validação final: NaNs, head(15) e resultados**

Apresentar a evolução do baseline da MecâniQA com validação temporal, métricas e features protegidas contra Data Leakage.

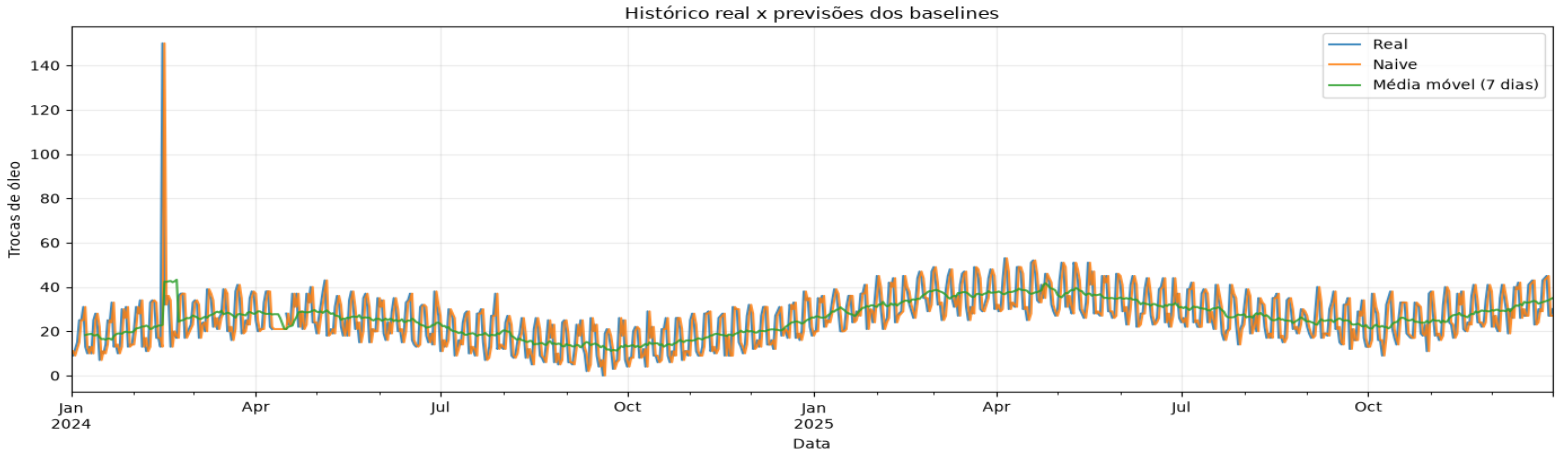
A DEMANDA APRESENTA SAZIONALIDADE E VARIAÇÕES

- Série diária de trocas de óleo
- Registros de 2024 e 2025
- Padrão semanal recorrente
- Picos dificultam o planejamento



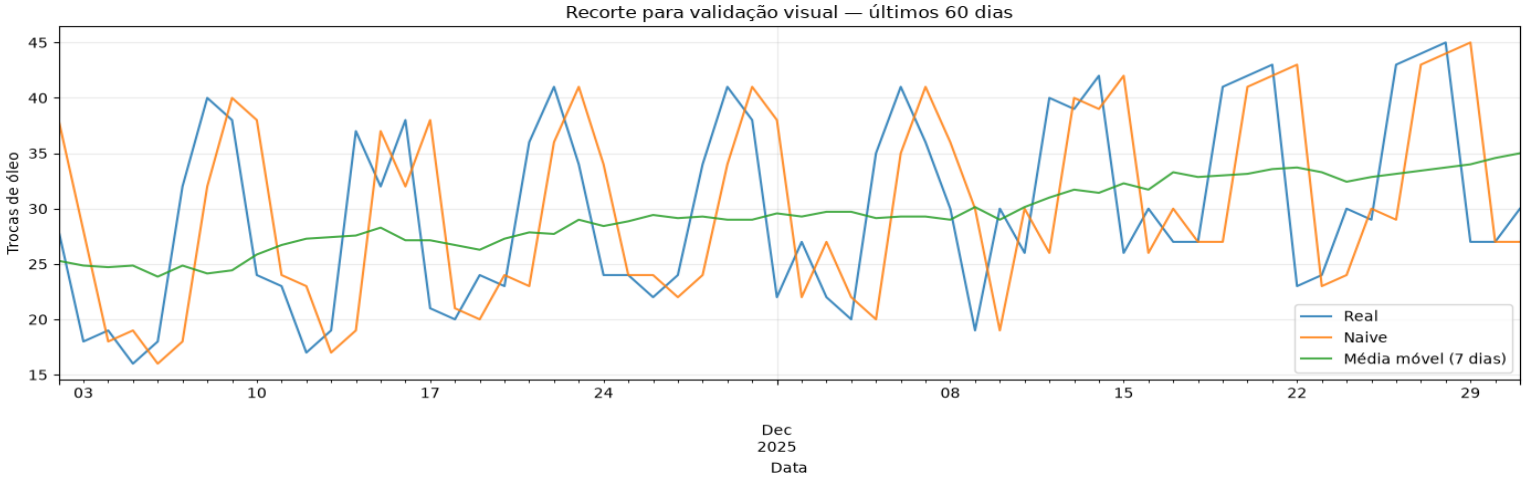
DOIS MODELOS DEFINEM O PONTO INICIAL DE COMPARAÇÃO

- Naive: repete o valor anterior
- Média móvel: últimos 7 dias
- Histórico real preservado
- Previsão de um dia à frente



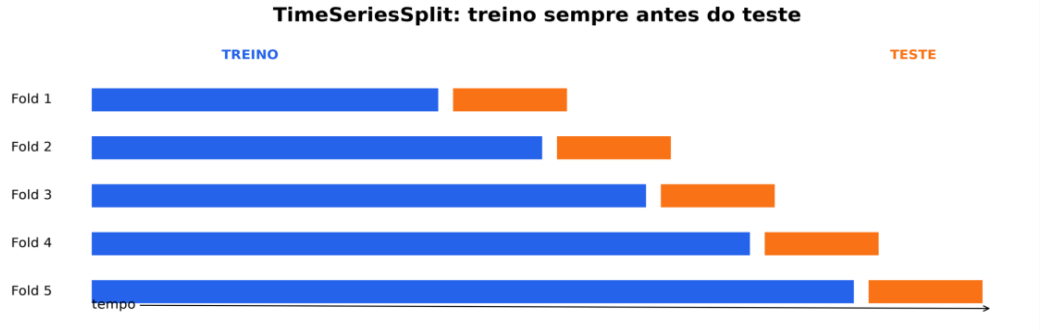
CADA PREVISÃO UTILIZA SOMENTE O PASSADO

- Uso de shift(1)
- Previsão de t usa até t-1
- Janelas após o deslocamento
- Nenhum acesso a dados futuros
- *Código: serie.shift(1).rolling(7).mean()*



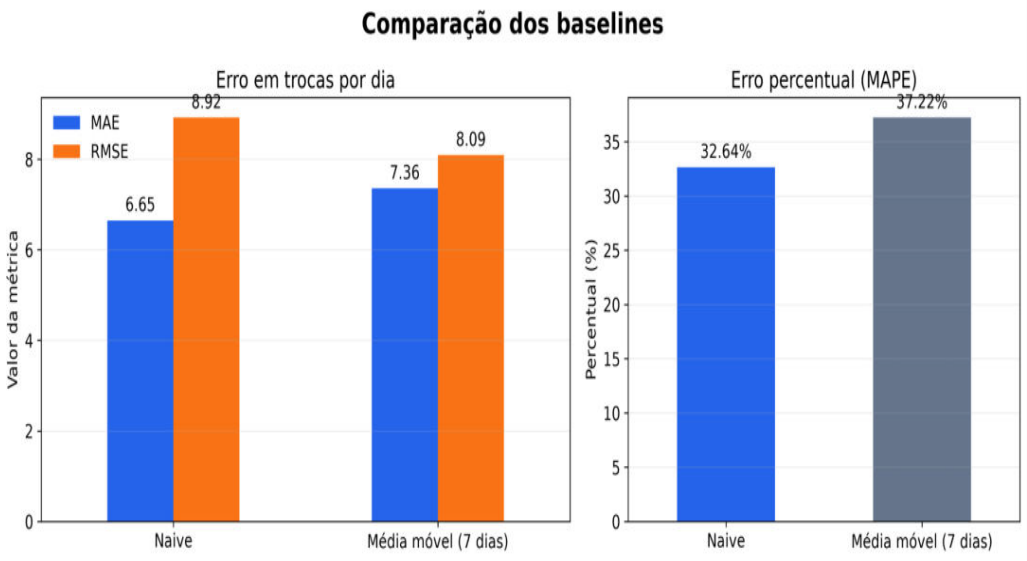
O TimeSeriesSplit MANTÉM TREINO ANTES DO TESTE

- Cinco divisões temporais
- Treino expansivo
- Teste sempre posterior
- Sem embaralhamento das datas



O NAIVE APRESENTOU MENOR ERRO MÉDIO

- Naive: MAE de 6,65
- Média móvel: MAE de 7,36
- Naive teve menor MAPE
- Média móvel teve menor RMSE



O Naive foi escolhido como baseline principal por apresentar o menor MAE. A média móvel teve menor RMSE, mas erros médios e percentuais maiores.

AS FEATURES PREPARAM OS DADOS PARA NOVOS MODELOS

- lag_1: comportamento recente
- lag_7: padrão semanal
- lag_30: referência mensal
- Janelas móveis de 7 e 30 dias
- NaNs removidos após o aquecimento

Features temporais alinhadas cronologicamente

	alvo	lag_1	lag_7	lag_30	rolling_7	rolling_30
31/01/2024	14.0	14.0	10.0	11.0	19.57	17.9
01/02/2024	21.0	14.0	13.0	9.0	20.14	18.0
02/02/2024	31.0	21.0	30.0	12.0	21.29	18.4
03/02/2024	28.0	31.0	26.0	15.0	21.43	19.03
04/02/2024	34.0	28.0	31.0	25.0	21.71	19.47
05/02/2024	13.0	34.0	13.0	25.0	22.14	19.77
06/02/2024	17.0	13.0	14.0	31.0	22.14	19.37

AS FEATURES FORAM VALIDADAS APÓS O PERÍODO DE AQUECIMENTO

- df.head(15) utilizado na conferência
- 66 linhas removidas durante o aquecimento e após lacunas no histórico
- 0 valores nulos após a limpeza
- Lags e médias móveis alinhados no tempo
- Nenhuma feature utiliza informações futuras

Data	alvo	lag_1	lag_7	lag_30	rolling_7	rolling_30
31/01/2024	14	14	10	11	19,57	17,90
01/02/2024	21	14	13	9	20,14	18,00
02/02/2024	31	21	30	12	21,29	18,40
03/02/2024	28	31	26	15	21,43	19,03
04/02/2024	34	28	31	25	21,71	19,47

Recorte de 5 das 15 primeiras linhas verificadas com df.head(15).

O descarte ocorre no início da série e nas janelas afetadas por valores ausentes, evitando preencher as features com informações futuras.

Conclusão

- Naive apresentou menor erro médio, com MAE de 6,65, contra 7,36 da Média Móvel.
- O uso de shift(1) e TimeSeriesSplit preservou a ordem temporal e evitou o uso de informações futuras.
- Lags 1, 7 e 30 e janelas móveis de 7 e 30 dias prepararam a base para modelos preditivos mais avançados.
- Os resultados obtidos passam a funcionar como referência de desempenho para comparar os próximos modelos da MecâniQA.